Децентрализованный алгоритм управления конвейерной системой с использованием методов мультиагентного обучения с подкреплением

Мухутдинов Дмитрий, группа М4239
Научный руководитель: Фильченков А. А., к.ф-м.н., доцент ФИТиП
Консультант: Вяткин В.В., д.т.н., профессор ФИТиП

Факультет Информационных Технологий и Программирования
Мегафакультет Трансляционных Информационных Технологий
Университет ИТМО, Санкт-Петербург

4 мая 2019 г.

Конвейерные системы

Применения:

- Промышленность
- Сортировка грузов
- Распределение багажа
- ...

Будем рассматривать случай с багажом.

Существующие решения

- Статические стратегии управления[1]
  - Разрабатываются под конкретную топологию системы
- Model predictive control (MPC)[2][3][4]
  - Решает глобальную оптимизационную задачу в форме LP/QP
  - Вся система контролируется централизованно
  - Не может обрабатывать изменения в системе, не заложенные в модель (поломки)
  - Не найдено алгоритма именно для багажных ленточных конвейеров
- Маршрутизация по аналогии с компьютерными сетями[5]
  - Децентрализованное вычисление, устойчивость к поломкам
  - Оптимизирует только скорость доставки чемоданов

---

[1] De Neufville.
[2] Cataldo, Scattolini.
[3] Zeinaly, De Schutter, Hellendoorn.
[4] Luo, Huang, Zhang.
[5] Yan, Vyatkin.

Цель работы

Разработать алгоритм управления конвейерной системой со следующими свойствами:

- Децентрализованность
- Многокритериальная оптимизация (время доставки багажа + энергопотребление)
- Устойчивость к разнородным изменениям в условиях среды
  - Изменения характеристик багажного потока
  - Поломки конвейеров

Идея

- Сосредоточимся на обобщенной задаче маршрутизации в ориентированном графе
- Обучение с подкреплением
- Нейросети в качестве обучающихся агентов
- Q-routing[6]
  - Не получил широкого распространения в компьютерных сетях (использует слишком много служебных пакетов)
  - В конвейерных сетях это не является проблемой.

[6] Boyan, Littman.

Постановка задачи в терминах RL

- Рассмотрим *пакет* в сети как обучающегося агента, взаимодействующего с сетью как со средой
- Полное состояние среды неизвестно, состояние текущего роутера — *наблюдение* пакета
- Действие — переход к одному из соседей
- Q-learning:

$$Q(o_t, a_t) \leftarrow r_t + \gamma \cdot \max_{a \in \mathcal{A}_{o_{t+1}}} Q(o_{t+1}, a)$$

- Принцип аналогичный Q-routing:

$$Q_x(d, y) \leftarrow (t_{finish} - t_{start}) + \max_{z \in \{V | (y,z) \in E\}} Q_y(d, z)$$

Что было сделано: алгоритм DQN-routing[7]

- Объединяет link-state протокол с алгоритмом Q-routing
- Вход нейросети:
  - Номер текущего узла n
  - Номер узла назначения d
  - Узлы-соседи Y
  - Матрица смежности графа
- Выход: $\{Q_x(d, y)\}_{y \in Y}$

Был протестирован в сеттинге компьютерных и конвейерных сетей

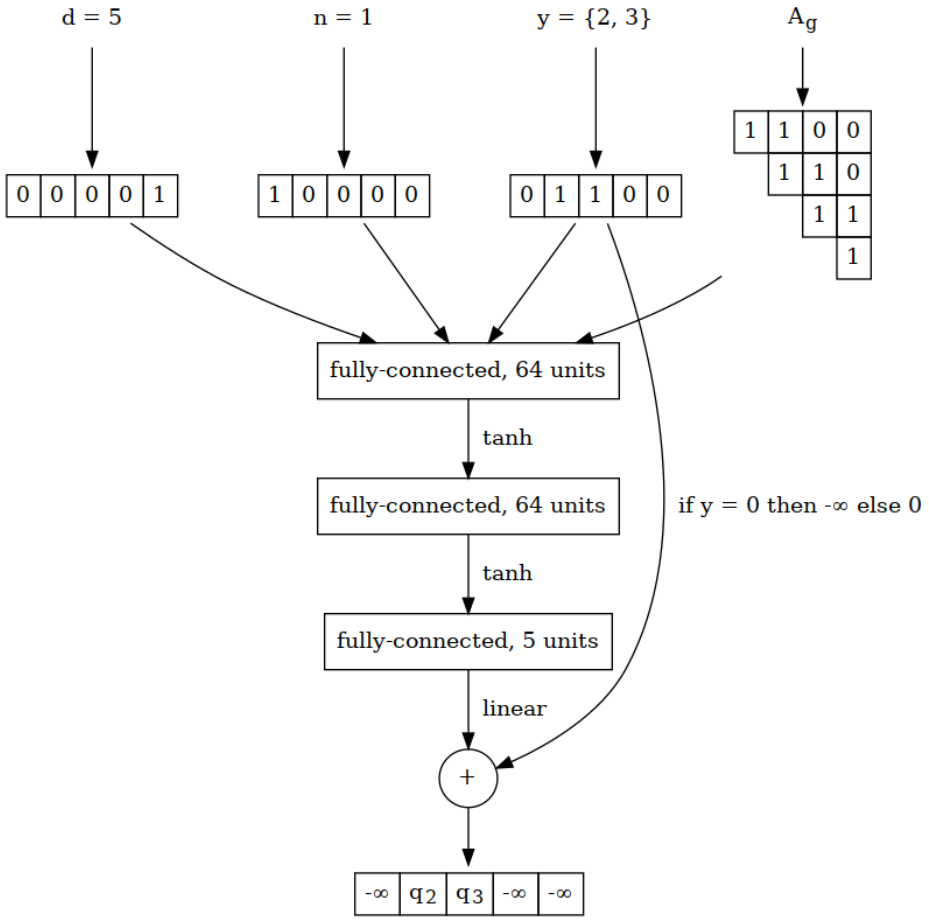

[7] "Multi-agent deep learning for simultaneous optimization for time and energy in distributed routing system".

Плюсы и минусы DQN-routing

- Плюсы
  - Адаптация под изменения трафика
  - Адаптация после поломок
  - Оптимизация времени доставки и энергопотребления с заданным приоритетом
- Минусы
  - Размер выходного слоя линейно зависит от размера графа
  - Размер входного слоя квадратично (!) зависит от размера графа
  - Требует предварительного обучения с учителем

Можно ли избавиться от минусов, не потеряв плюсов?

Идеи усовершенствования алгоритма

- Предсказание Q-функции отдельно для каждого исходящего ребра
  - Вместо множества текущих соседей подаем на вход одного соседа y.
  - Один нейрон на выходном слое выдает скалярное значение $Q_x(d, y)$
- Использование графовых эмбеддингов
  - Вместо кодирования меток узлов унитарным кодом использовать их отображения в векторное пространство фиксированной размерности
  - Отказ от подачи на вход матрицы смежности
    - Вместо этого пересчитывать эмбеддинги при изменении топологии
    - Эмбеддинги косвенно передадут информацию о топологии

Модификация: DQN-LE-routing

- Получаем эмбеддинги методом Laplacian Eigenmaps (LE)
- Нормализуем веса ребер по среднему перед расчетом
- Полученные эмбеддинги домножаем на средний вес

Тогда

$$Q_n(d, y) = f_\theta((LE_G(d) - LE_G(n)) \odot (LE_G(y) - LE_G(n)))$$

, где:

- $LE_G(\cdot)$ возвращает эмбеддинг по номеру узла
- $f_\theta(\cdot)$ — feed-forward нейронная сеть

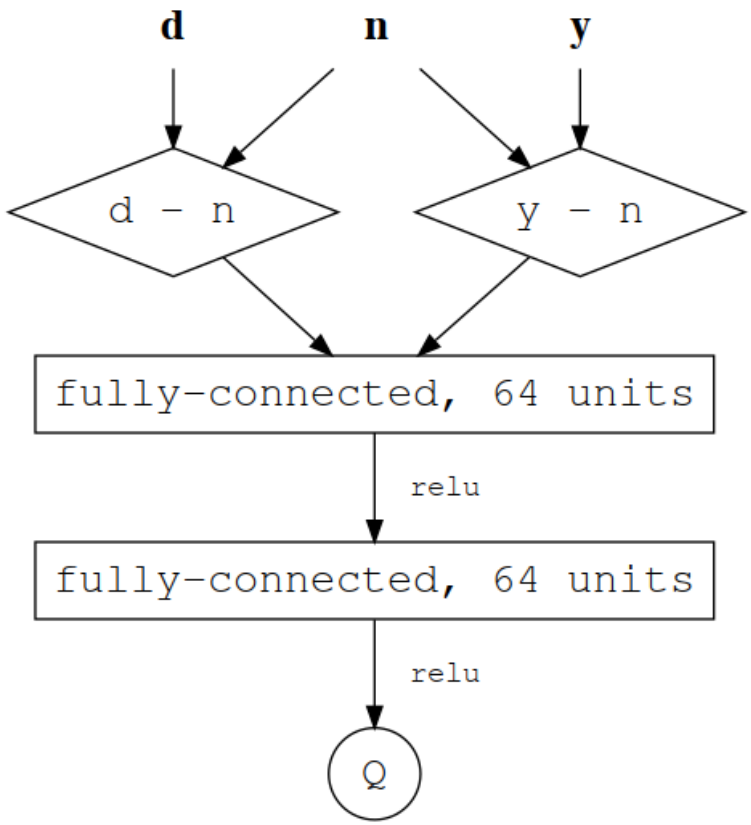

Эксперименты в модели компьютерной сети

- Запуск экспериментов в симуляторе
- Размерность эмбеддинга: 8
- Бейзлайны:
  - Табличный Q-routing
  - Дейкстра с протоколом link-state (shortest paths, SP)
  - Оригинальный DQN-routing (DQN)
- Служебные сообщения доставляются бесплатно
- Зачем?
  - Быстрее симулировать, чем конвейеры
  - Показываем универсальность алгоритма

Эксперименты в модели компьютерной сети: предобучение

- У нетабличного Q-обучения нет гарантий сходимости (2)
- Experience replay не работает в нестационарной среде
- Предобучаем на действиях алгоритма shortest paths
- Получаем данные на базовом графе (1) и его модификациях

Рис. 1: Базовая топология сети для тестов

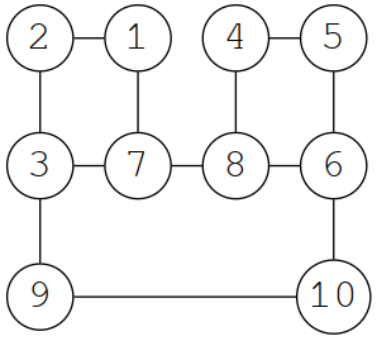

Рис. 2: Работа DQN без предобучения

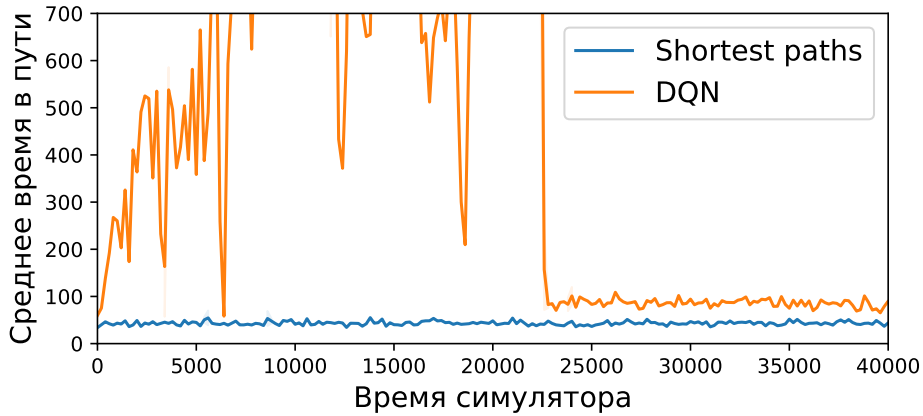

Эксперименты: резкое изменение нагрузки

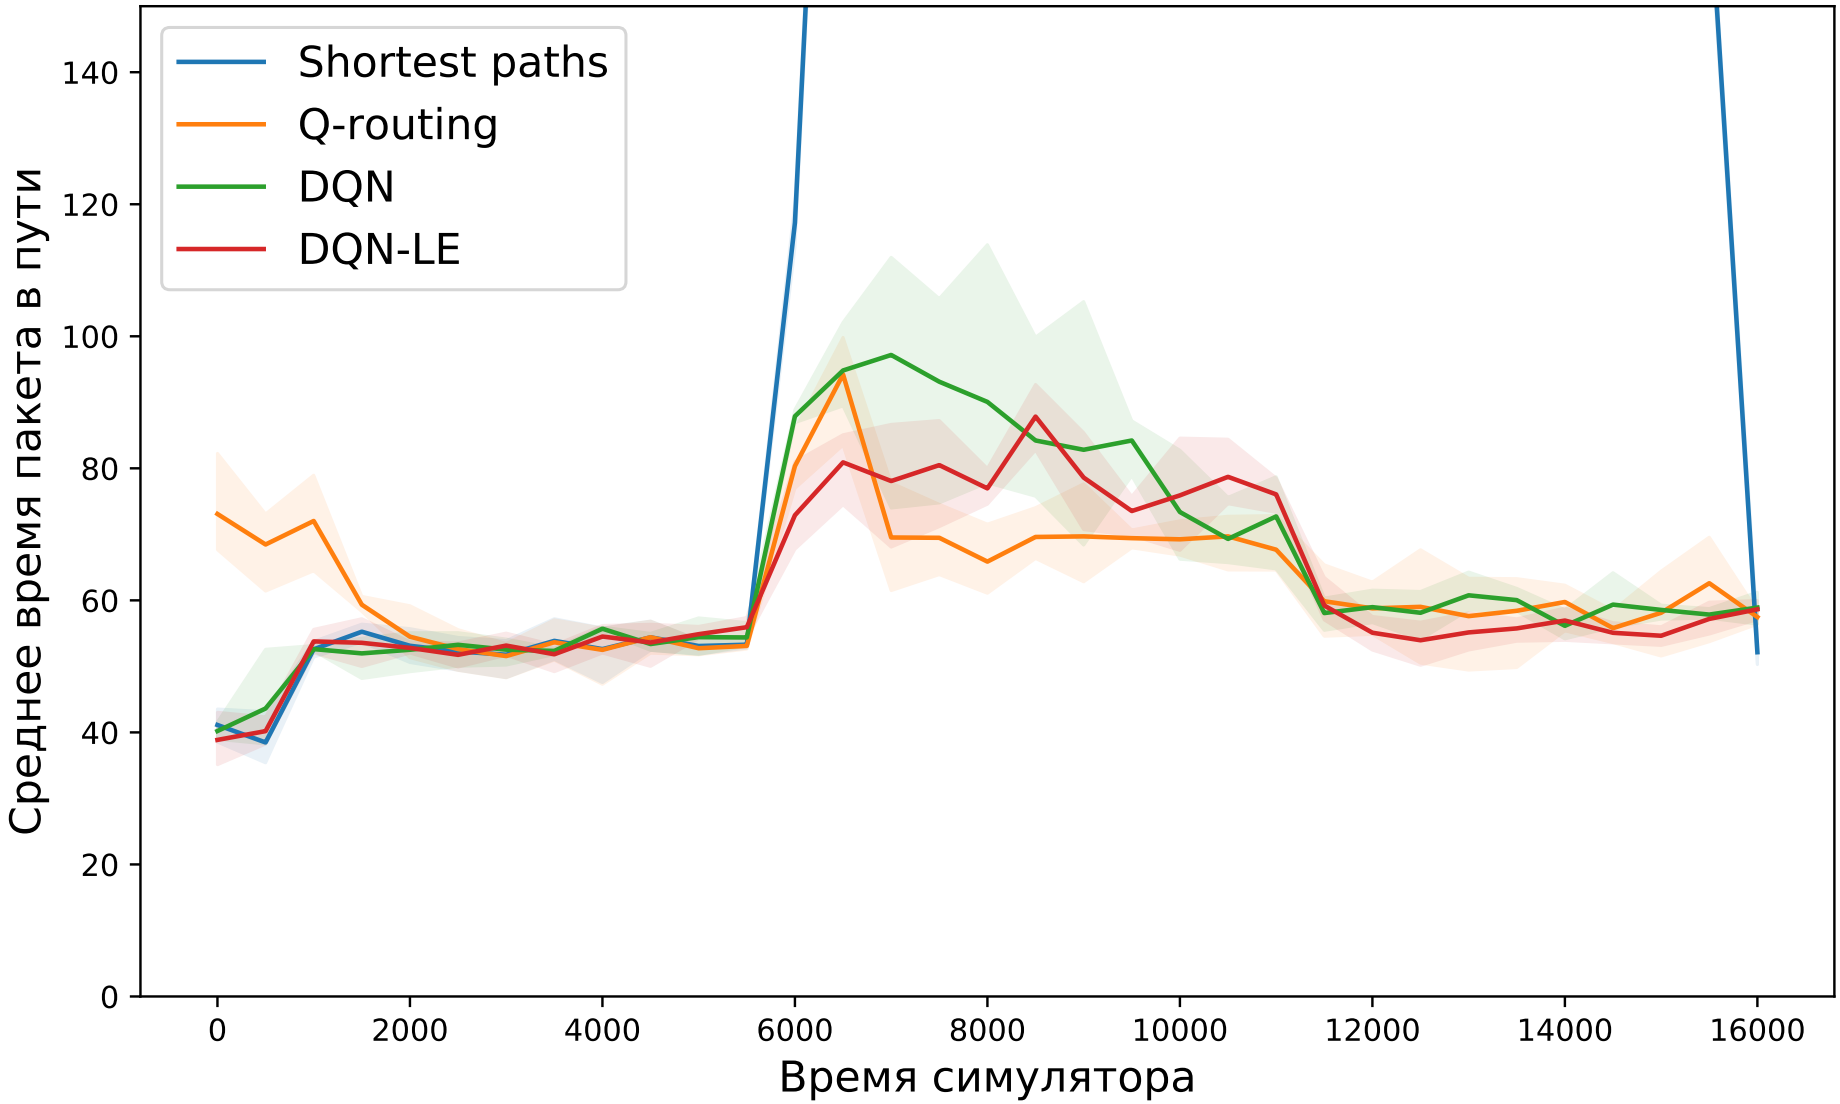

Эксперименты: обрыв и восстановление соединений

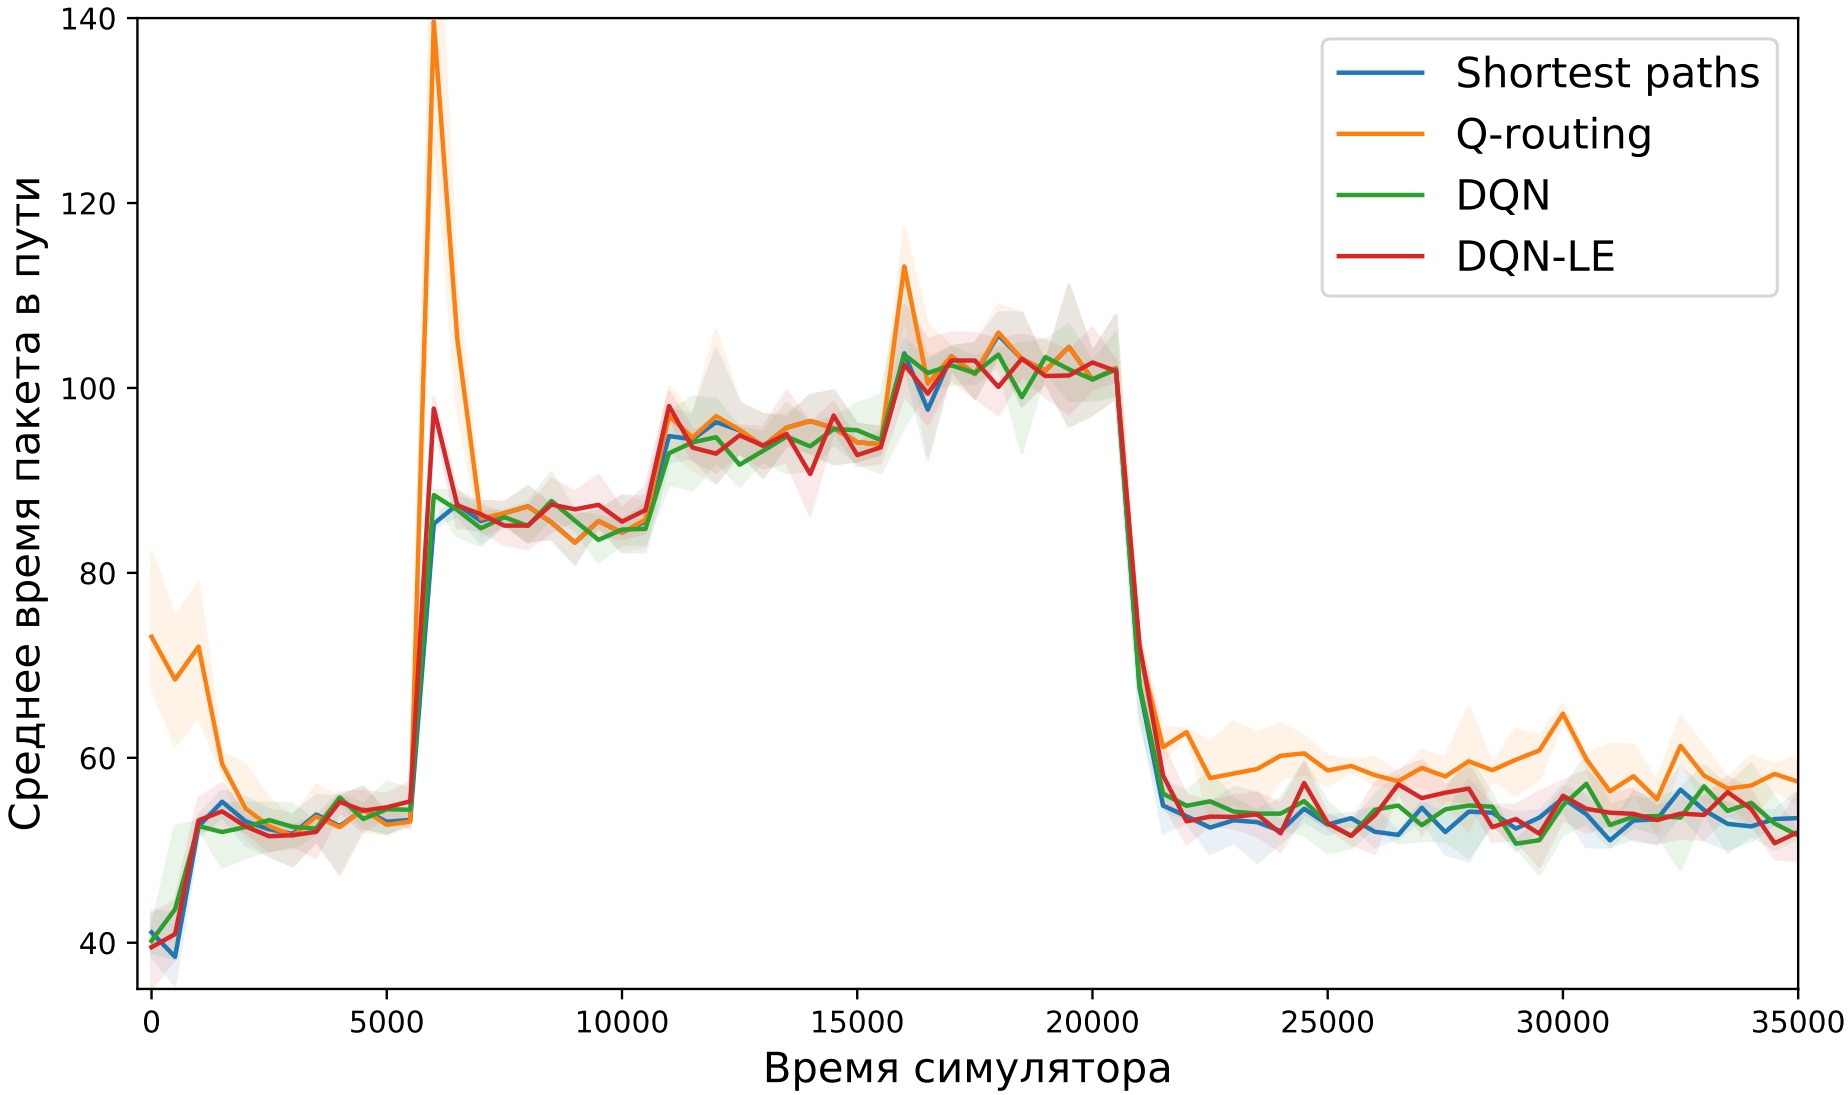

Перенос опыта на новую топологию

- DQN-LE-routing все еще требует предобучения
- Однако, если опыт переносится на совершенно новые топологии, это не страшно
- Проверим производительность на случайном графе

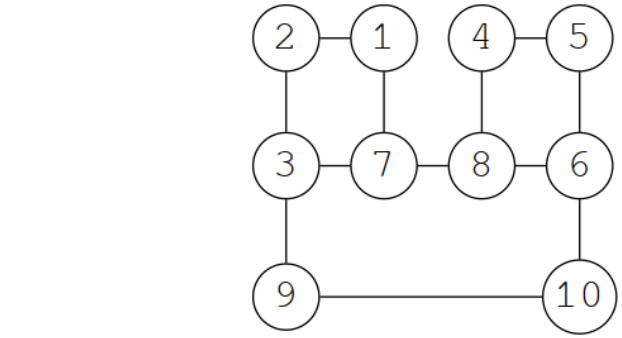

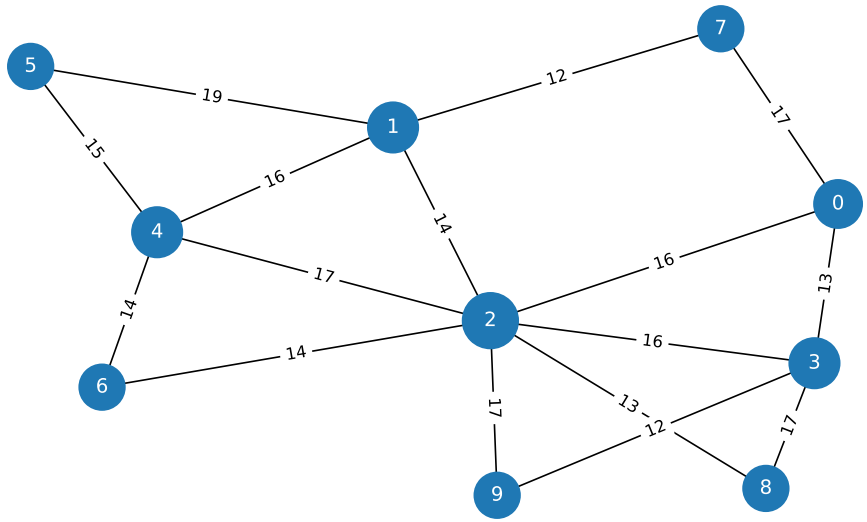

Перенос опыта на новую топологию: то же кол-во вершин

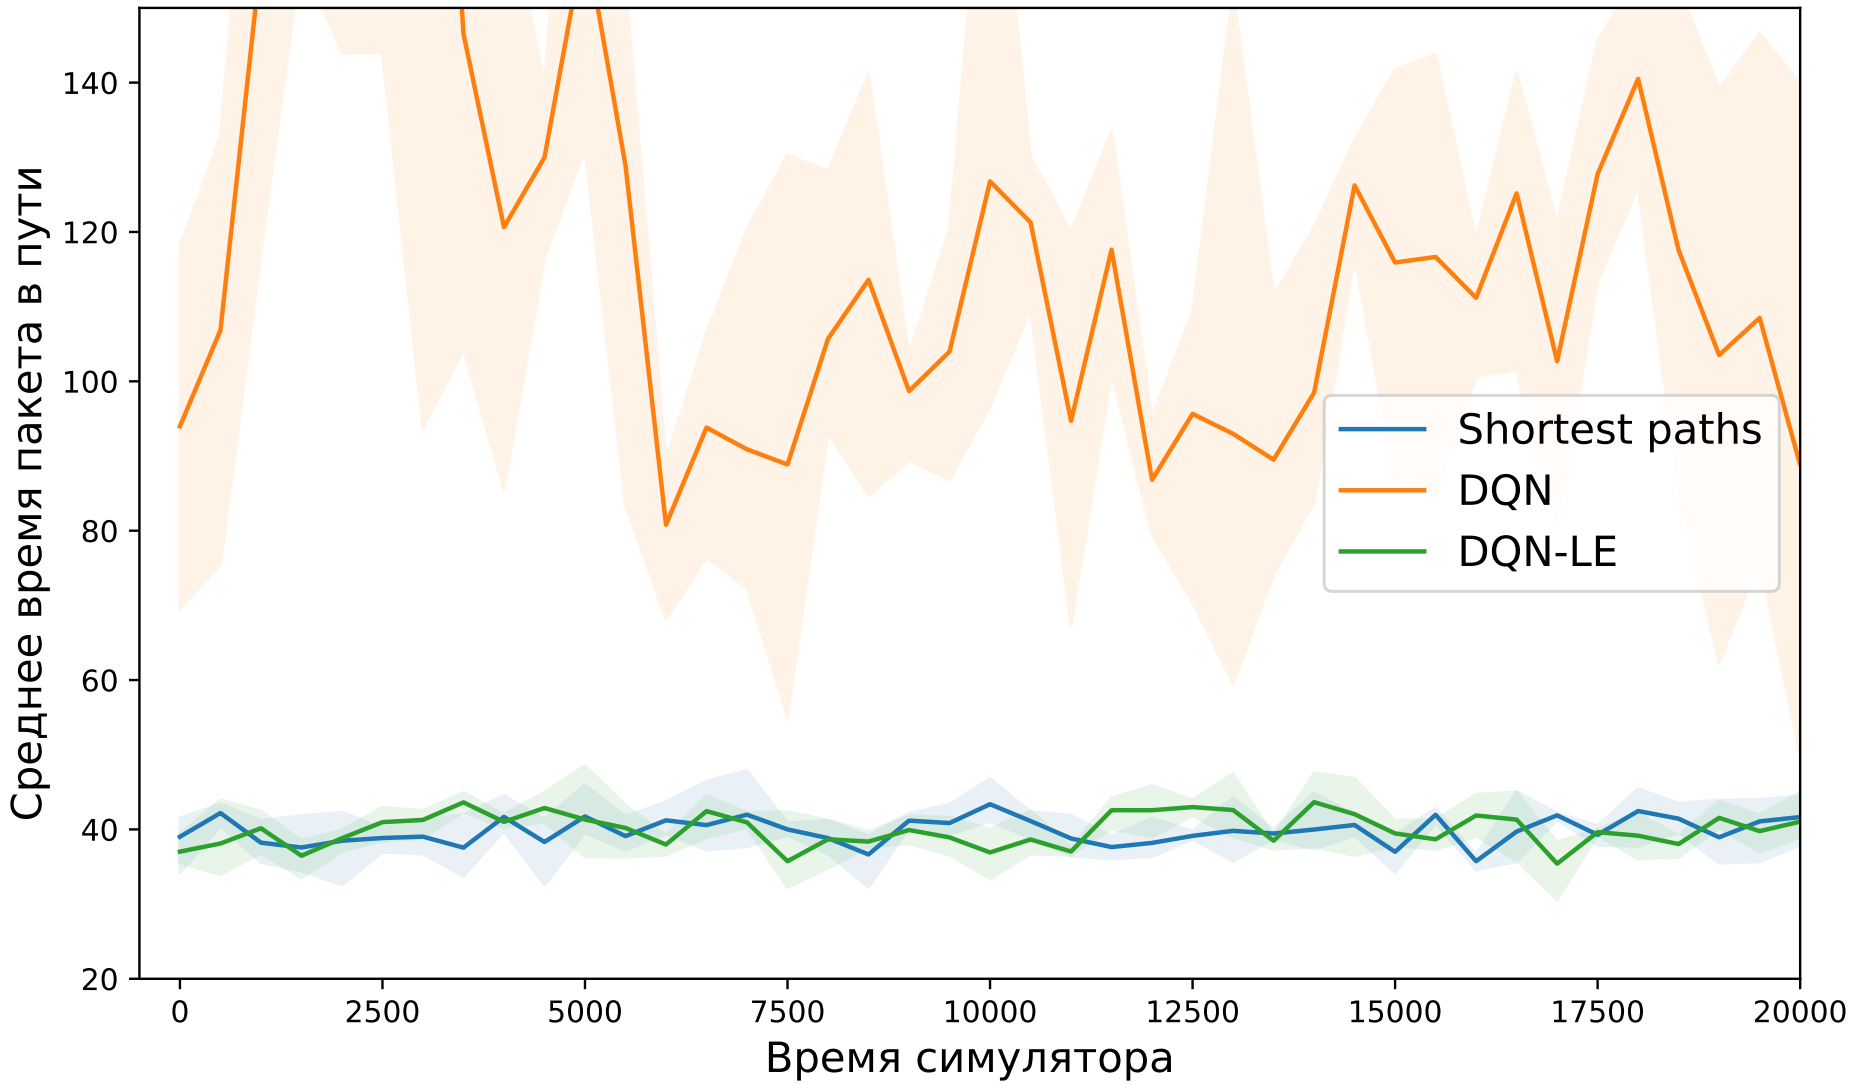

Перенос опыта на новую топологию: большее кол-во вершин

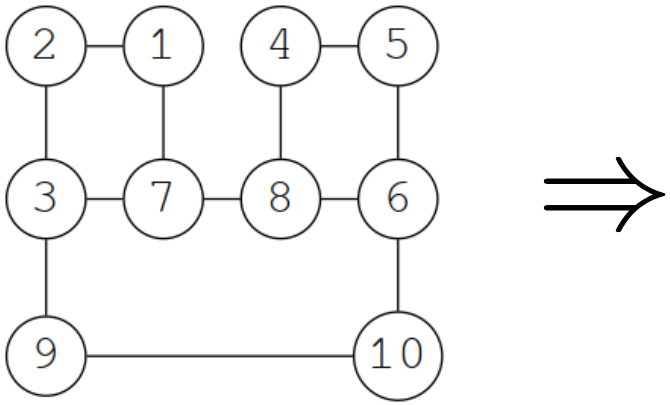

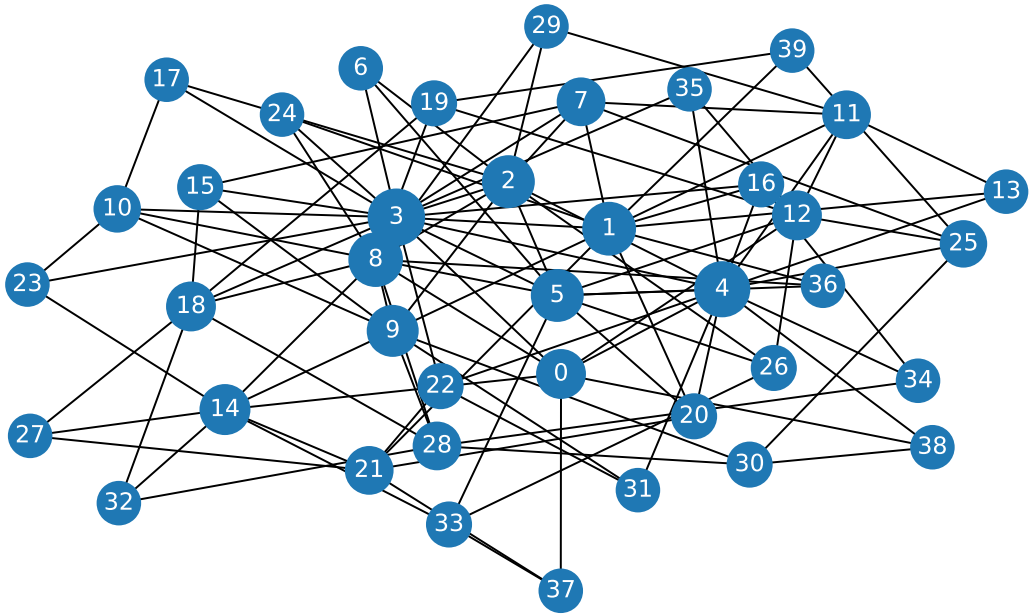

Перенос опыта на новую топологию: большее кол-во вершин

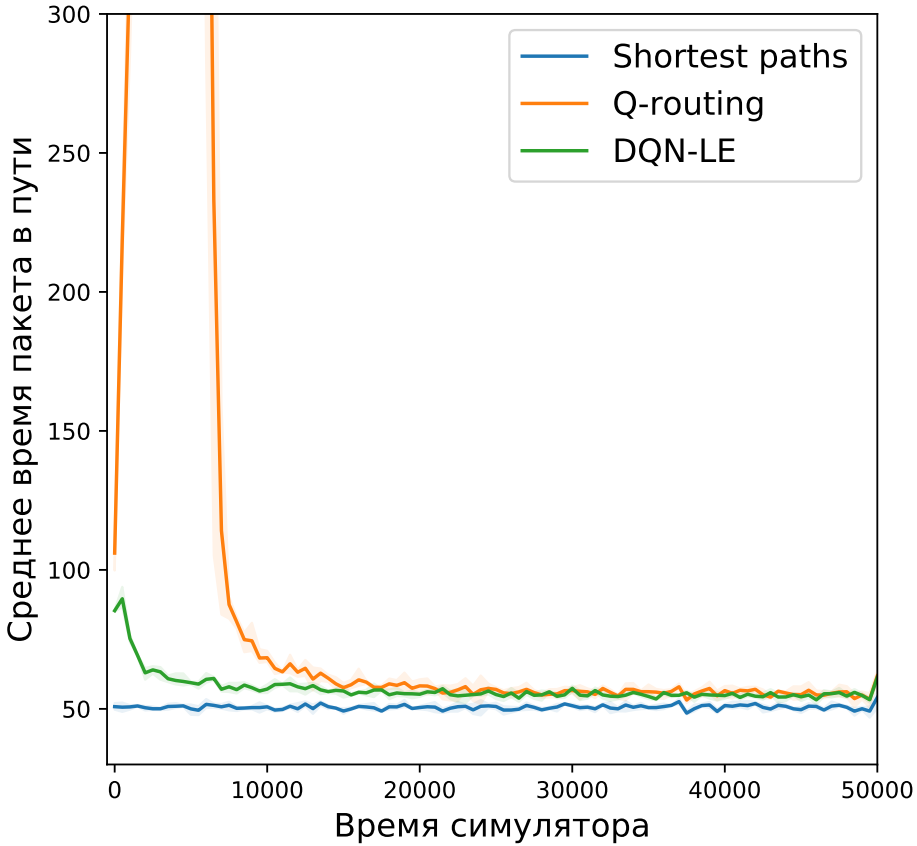

Рис. 3: Низкая нагрузка

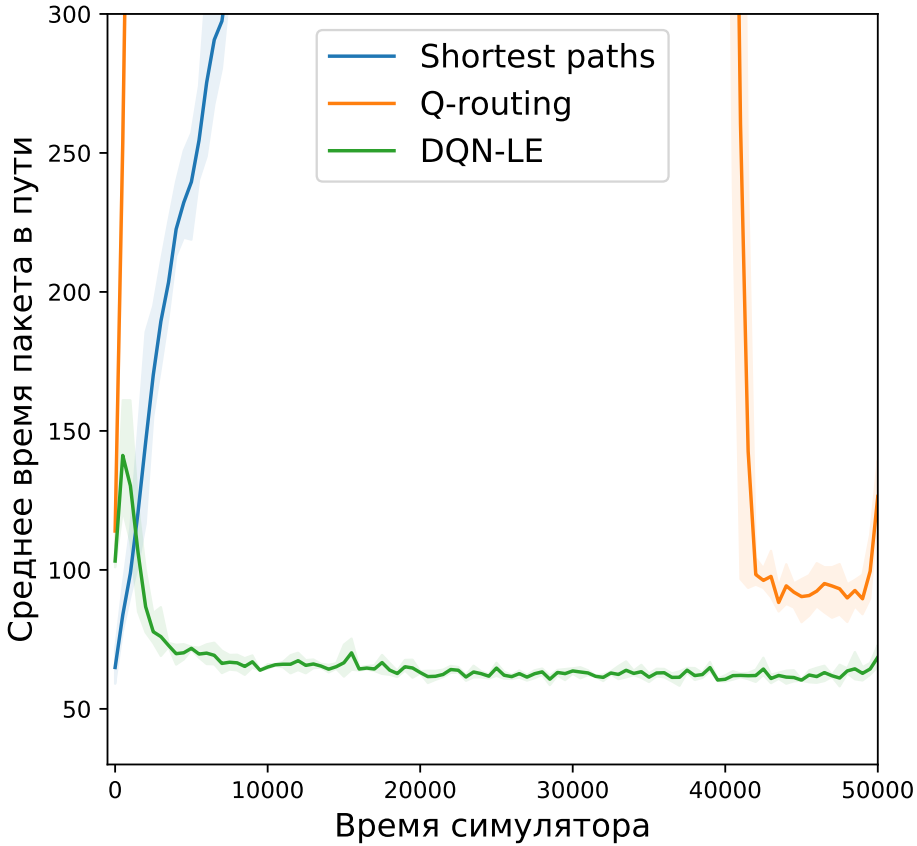

Рис. 4: Высокая нагрузка

Эксперименты в модели системы багажных конвейеров

- Конвейерная сеть моделируется как ориентированный граф
- Каждая секция конвейера – отдельная вершина
- В оптизируемую функцию включено *энергопотребление*
- На вход нейросети дополнительно подается информация о состоянии конвейеров
- Важность экономии энергии регулируется параметром α
- Размерность эмбеддинга: 10

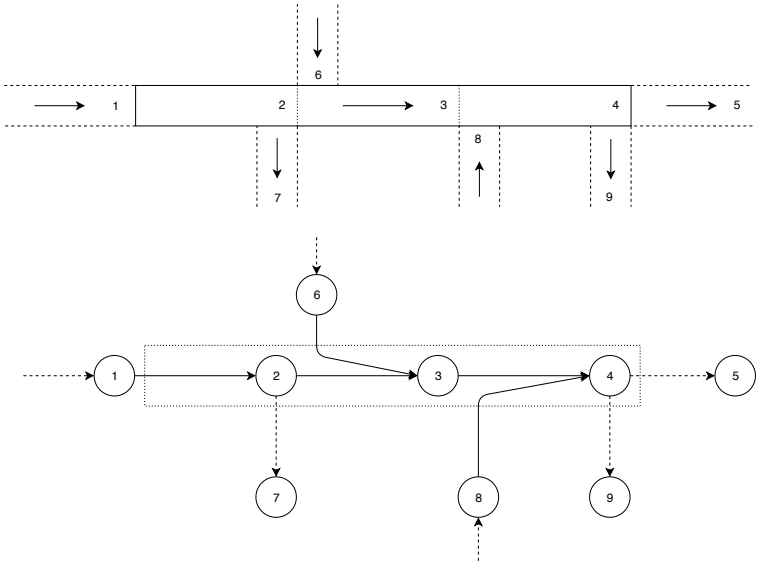

Рис. 5: Участок конвейерной сети и соответствующий участок графа

Модель конвейерной системы для проведения экспериментов

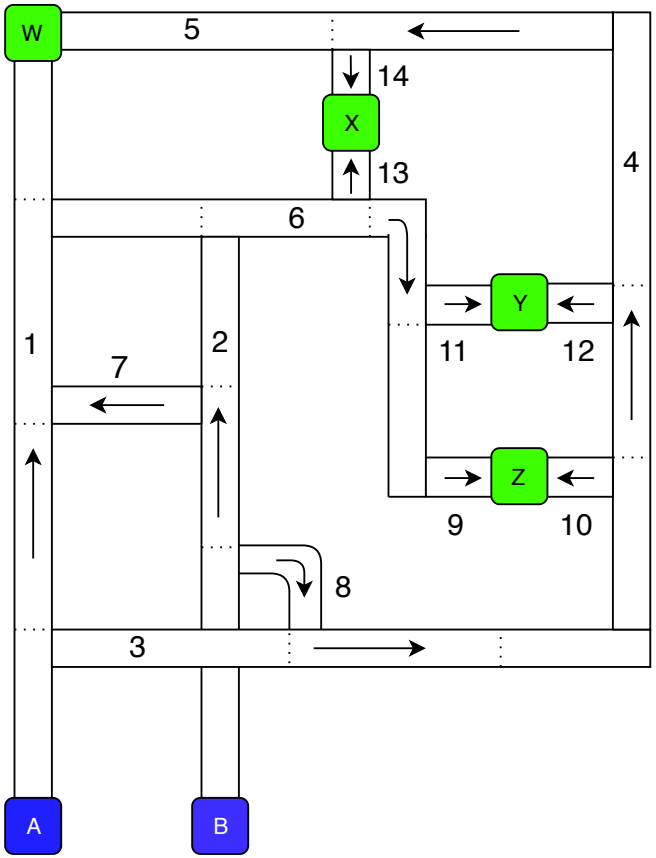

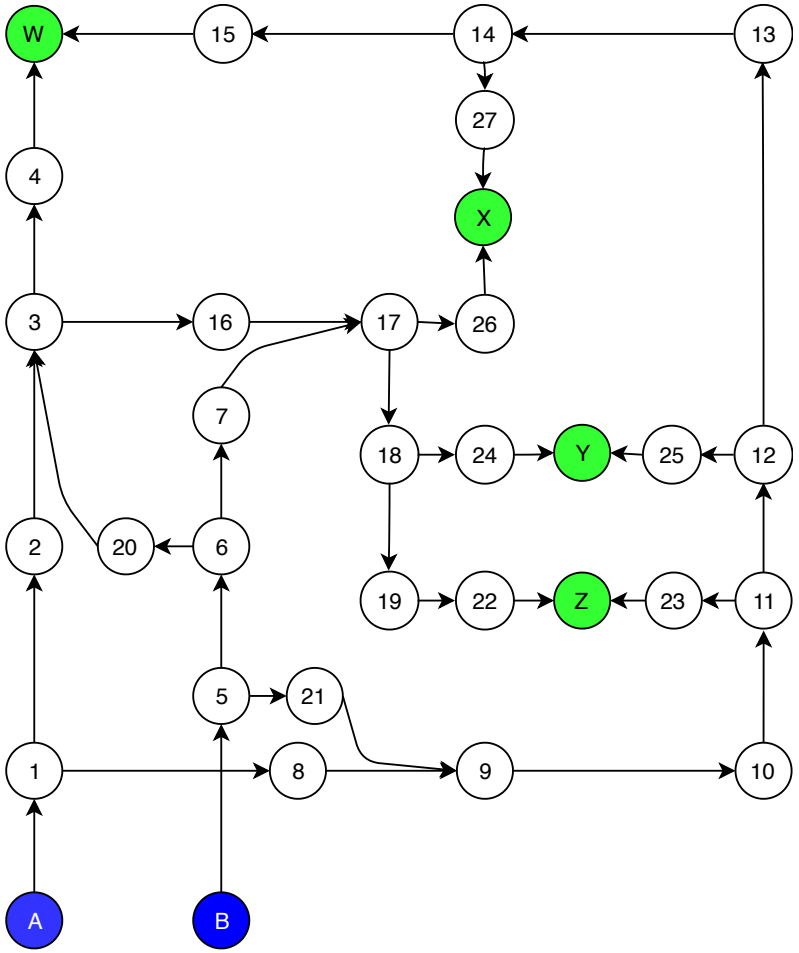

Неравномерный поток до выходных вершин

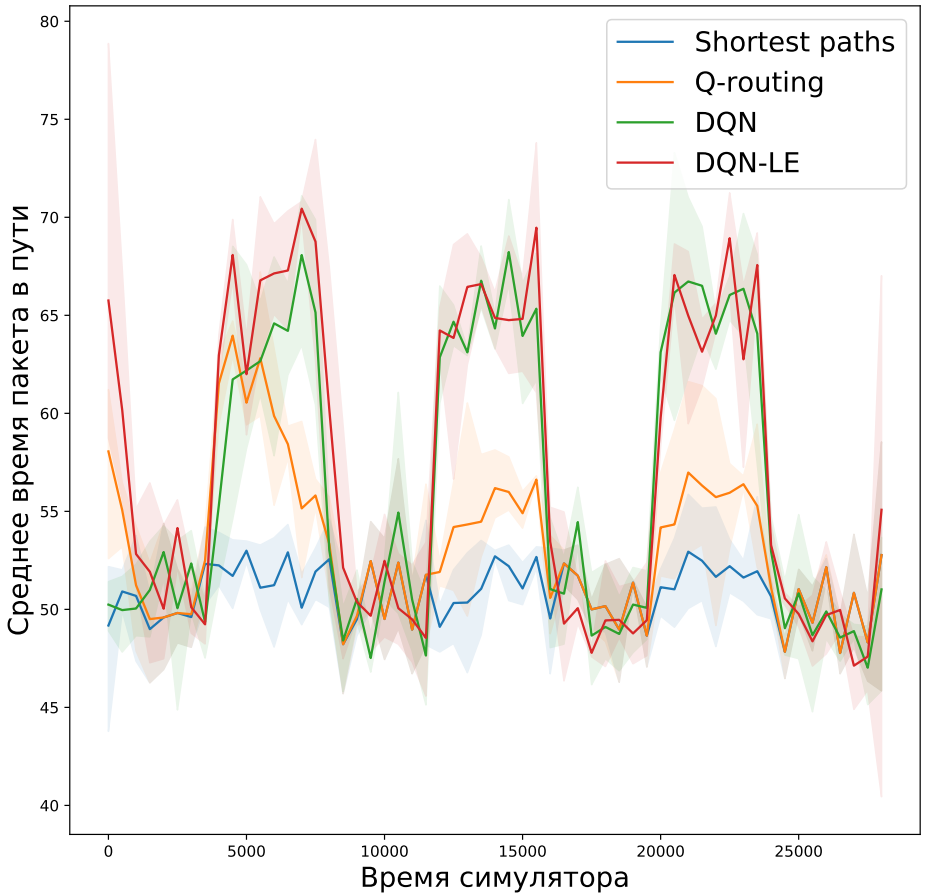

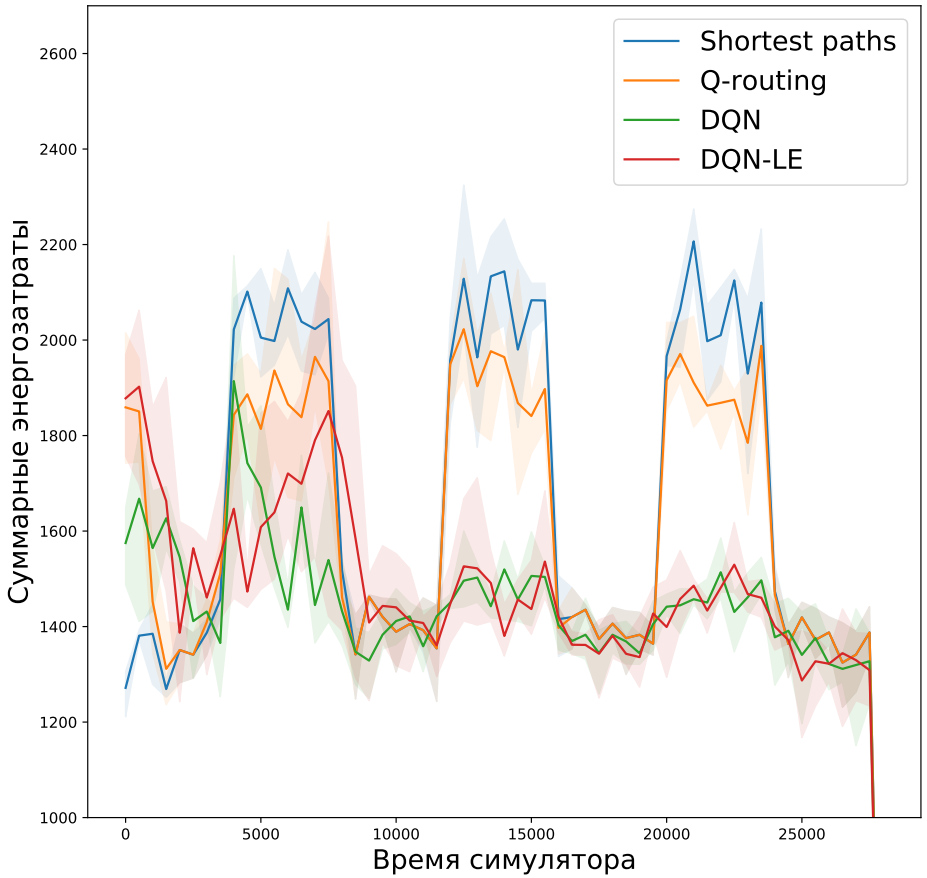

Плавное повышение нагрузки: $\alpha = 1$, $\alpha_{LE} = 0.4$

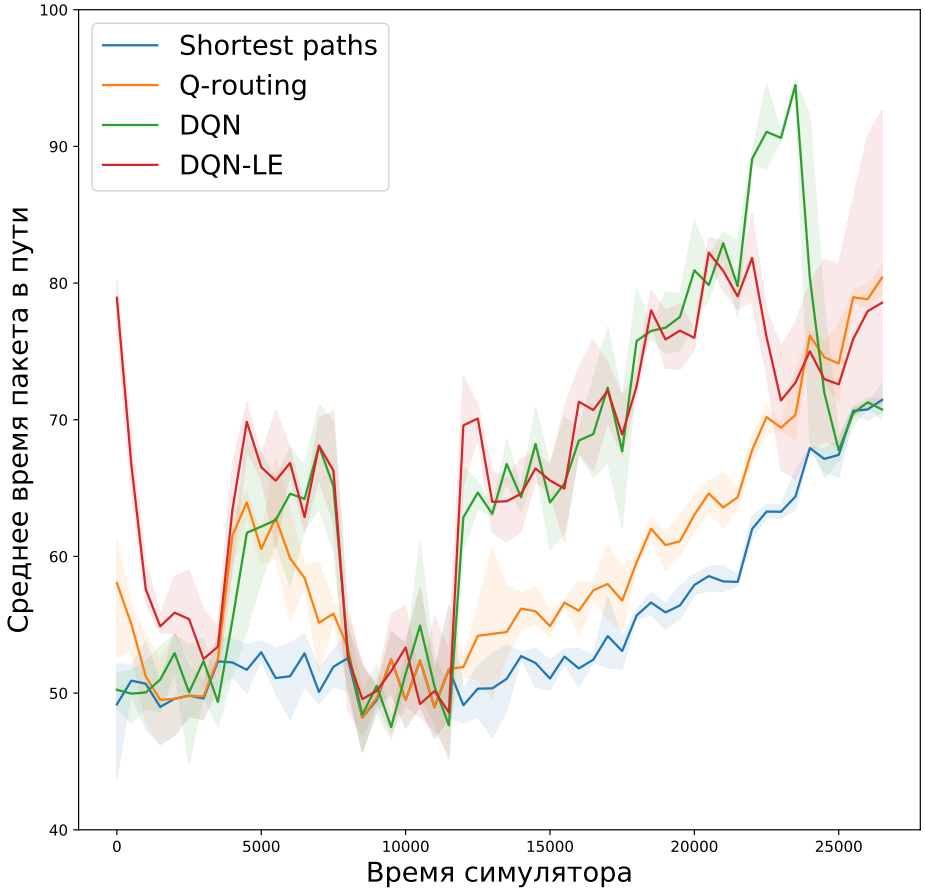

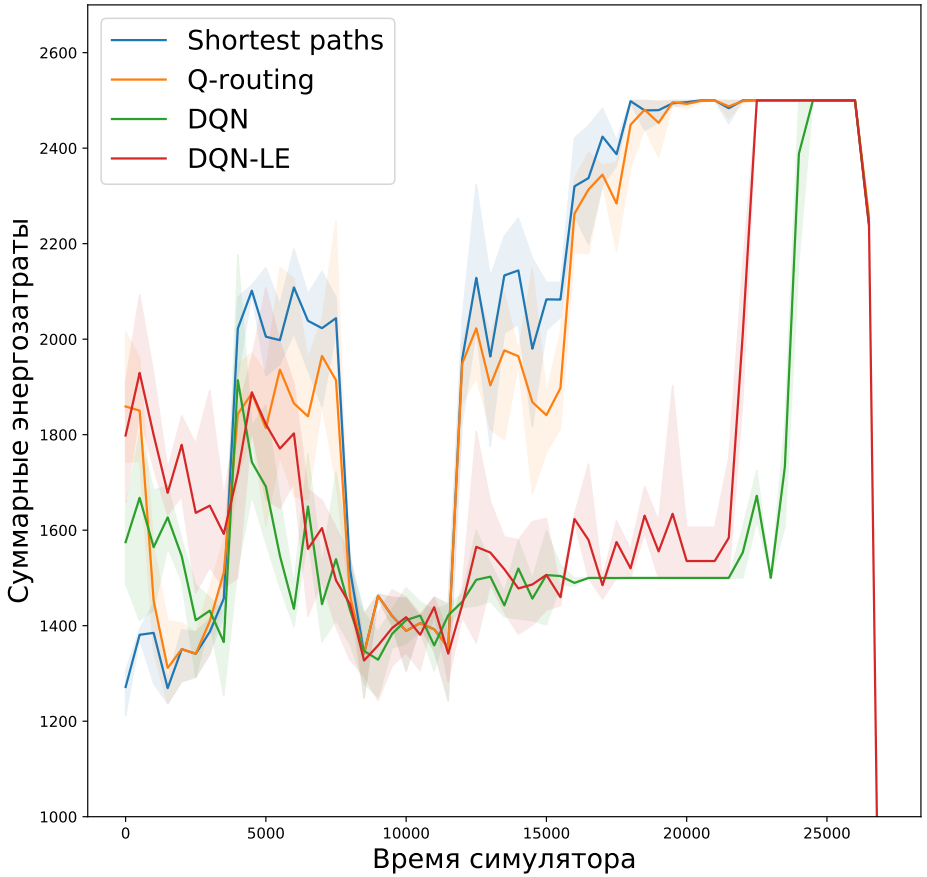

Плавное повышение нагрузки: $\alpha = 0.8$, $\alpha_{LE} = 0.2$

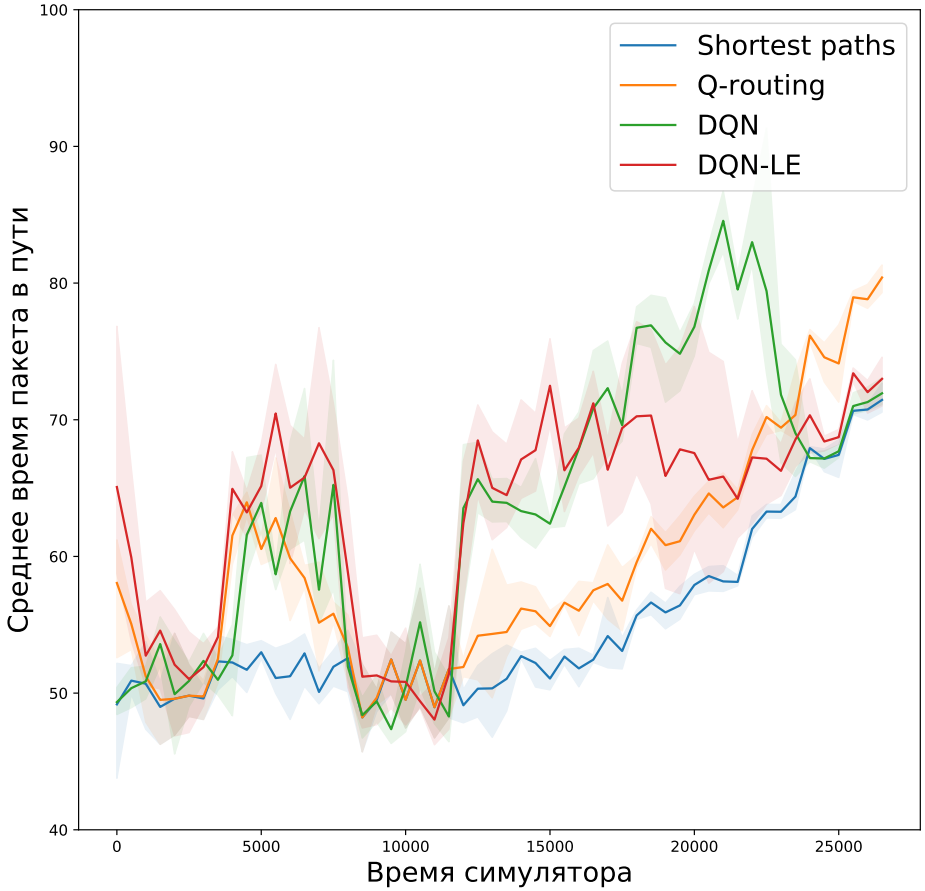

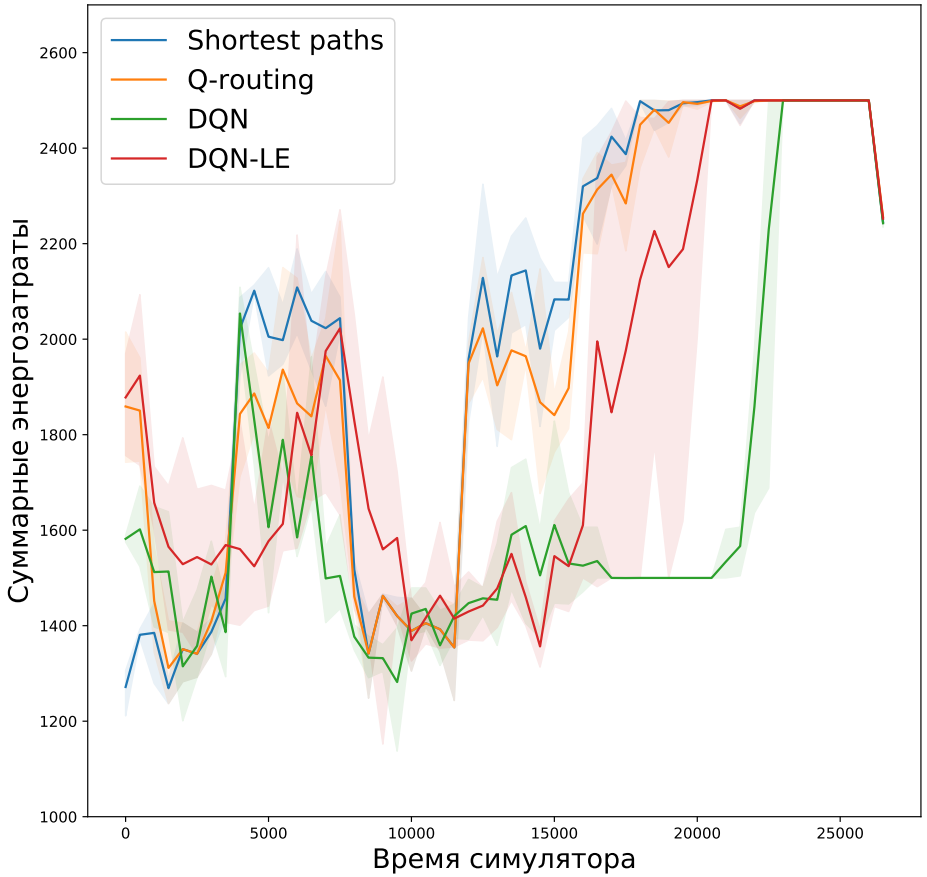

Итоги

- Разработана модификация алгоритма DQN-routing — DQN-LE-routing
- Модифицированный алгоритм свободен от ключевых недостатков DQN-routing:
  - Зависимость размера нейронной сети от размера графа
  - Необходимость переобучения с учителем на новых графах
- Не уступает изначальному алгоритму по качеству работы в модели компьютерной или конвейерной сети

Направления дальнейших исследований

- Поиск/изобретение более качественных бейзлайнов (например, на основе MPC)
- Исследование идеи глобальной графовой нейронной сети[8][9][10]
- Проведение большего числа экспериментах на различных топологиях
  - В т. ч. случайная генерация правдоподобных конвейерных сетей
- Выход за пределы маршрутизации
  - Обучение контроллера скорости конвейера

[8] “The graph neural network model”.

[9] “Gated graph sequence neural networks”.

[10] Geyer, Carle.

Спасибо за внимание!

Глобальная графовая нейронная сеть: идея

- Рассматриваем весь граф с состояниями ребер и узлов как вход для графовой нейронной сети (GG-NN)
- Считается распределенно на физических узлах системы
- Промежуточные состояния и их градиенты передаются между узлами по сети
  - Применяется для компьютерных сетей с обучением с учителем[11]
  - Добавим обучение с подкреплением во время работы

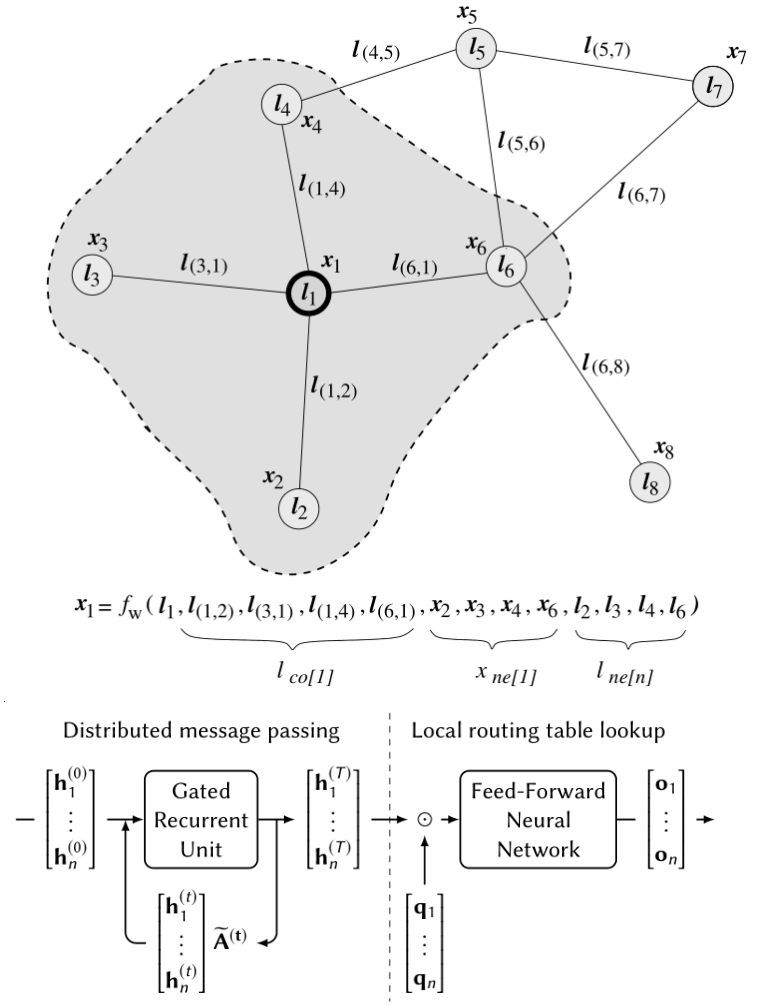

[11] Geyer, Carle.